


Metropolisův algoritmus

Sociální systémy a jejich simulace
Jana Vacková

13.10.2021



Katedra matematiky FJFI ČVUT v Praze

- Termodynamický plyn
- Metropolisův algoritmus
 - Obecné odvození
 - Pro náš termodynamický plyn



Úvod - doprava a termodynamika

- Dopravní proud = částice, které mezi sebou interagují
- Rozdělení odstupů mezi částicemi zrcadlí onu interakci (01MMD)
- Fyzikální koncept: interakci popíšeme pomocí interakčních potenciálů

- Dopravní proud = částice, které mezi sebou interagují
- Rozdělení odstupů mezi částicemi zrcadlí onu interakci (01MMD)
- Fyzikální koncept: interakci popíšeme pomocí interakčních potenciálů

Termodynamický plyn:

- N částic na kruhu, teplotní rezervoár
- Konfigurace (polohy částic) $x = (x_1, \dots, x_N)$
- Interakce částic popsána potenciální energií $U(x)$, proto energie konfigurace $E(x) = U(x)$

Úvod - doprava a termodynamika

- Dopravní proud = částice, které mezi sebou interagují
- Rozdělení odstupů mezi částicemi zrcadlí onu interakci (01MMD)
- Fyzikální koncept: interakci popíšeme pomocí interakčních potenciálů

Termodynamický plyn:

- N částic na kruhu, teplotní rezervoár
- Konfigurace (polohy částic) $x = (x_1, \dots, x_N)$
- Interakce částic popsána potenciální energií $U(x)$, proto energie konfigurace $E(x) = U(x)$
- Boltzmannovo rozdělení

$$\pi(x) \propto \exp \left\{ -\frac{E(x)}{kT} \right\},$$

kde k je Boltzmannova konstanta a T termodynamická teplota

- Inverzní termodynamická teplota $\beta = \frac{1}{kT} \in \mathbb{R}^+$

Úvod - doprava a termodynamika

- Dopravní proud = částice, které mezi sebou interagují
- Rozdělení odstupů mezi částicemi zrcadlí onu interakci (01MMD)
- Fyzikální koncept: interakci popíšeme pomocí interakčních potenciálů

Termodynamický plyn:

- N částic na kruhu, teplotní rezervoár
- Konfigurace (polohy částic) $x = (x_1, \dots, x_N)$
- Interakce částic popsána potenciální energií $U(x)$, proto energie konfigurace $E(x) = U(x)$
- Boltzmannovo rozdělení

$$\pi(x) \propto \exp \left\{ -\frac{E(x)}{kT} \right\},$$

kde k je Boltzmannova konstanta a T termodynamická teplota

- Inverzní termodynamická teplota $\beta = \frac{1}{kT} \in \mathbb{R}^+$

Jak budeme takové polohy částic simulovat?

Úvod - doprava a termodynamika

- Dopravní proud = částice, které mezi sebou interagují
- Rozdělení odstupů mezi částicemi zrcadlí onu interakci (01MMD)
- Fyzikální koncept: interakci popíšeme pomocí interakčních potenciálů

Termodynamický plyn:

- N částic na kruhu, teplotní rezervoár
- Konfigurace (polohy částic) $x = (x_1, \dots, x_N)$
- Interakce částic popsána potenciální energií $U(x)$, proto energie konfigurace $E(x) = U(x)$
- Boltzmannovo rozdělení

$$\pi(x) \propto \exp \left\{ -\frac{E(x)}{kT} \right\},$$

kde k je Boltzmannova konstanta a T termodynamická teplota

- Inverzní termodynamická teplota $\beta = \frac{1}{kT} \in \mathbb{R}^+$

Jak budeme takové polohy částic simulovat? **Markov Chain Monte Carlo**

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)
- *Matice přechodu* P , kde $P(x, y)$ značí pravděpodobnost přechodu ze stavu x do stavu y , $x, y \in \mathcal{X}$ a $\sum_{y \in \mathcal{X}} P(x, y) = 1$

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)
- *Matice přechodu* P , kde $P(x, y)$ značí pravděpodobnost přechodu ze stavu x do stavu y , $x, y \in \mathcal{X}$ a $\sum_{y \in \mathcal{X}} P(x, y) = 1$
- *Stacionární rozdělení (SR)* π Markovského řetězce splňuje $\pi = \pi P$

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)
- *Matice přechodu* P , kde $P(x, y)$ značí pravděpodobnost přechodu ze stavu x do stavu y , $x, y \in \mathcal{X}$ a $\sum_{y \in \mathcal{X}} P(x, y) = 1$
- *Stacionární rozdělení (SR)* π Markovského řetězce splňuje $\pi = \pi P$
- *Detailní rovnováha* (detailed balance equations)

$$\pi(x) P(x, y) = \pi(y) P(y, x) \quad \forall x, y \in \mathcal{X}$$

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)
- *Matice přechodu* P , kde $P(x, y)$ značí pravděpodobnost přechodu ze stavu x do stavu y , $x, y \in \mathcal{X}$ a $\sum_{y \in \mathcal{X}} P(x, y) = 1$
- *Stacionární rozdělení (SR)* π Markovského řetězce splňuje $\pi = \pi P$
- *Detailní rovnováha* (detailed balance equations)

$$\pi(x) P(x, y) = \pi(y) P(y, x) \quad \forall x, y \in \mathcal{X}$$

- *Konvergenční teorém*: pokud necháme běžet MŘ dostatečně dlouho, distribuce bude blízka π

Markovské řetězce (MŘ) - opakování

- Další stav závisí pouze na předchozím stavu
- Ozn. \mathcal{X} prostor všech možných stavů (stavový prostor)
- *Matice přechodu* P , kde $P(x, y)$ značí pravděpodobnost přechodu ze stavu x do stavu y , $x, y \in \mathcal{X}$ a $\sum_{y \in \mathcal{X}} P(x, y) = 1$
- *Stacionární rozdělení (SR)* π Markovského řetězce splňuje $\pi = \pi P$
- *Detailní rovnováha* (detailed balance equations)

$$\pi(x) P(x, y) = \pi(y) P(y, x) \quad \forall x, y \in \mathcal{X}$$

- *Konvergenční teorém*: pokud necháme běžet MŘ dostatečně dlouho, distribuce bude blízka π
- **MCMC algoritmy** = třída algoritmů na vzorkování z π pomocí MŘ, jehož matici přechodu P neznáme (opačná úloha k hledání SR MŘ)

MCMC - Metropolisův algoritmus - úvod

- **MCMC algoritmy** = třída algoritmů na vzorkování z π pomocí MŘ, jehož matici přechodu P neznáme (opačná úloha k hledání SR MŘ)

MCMC - Metropolisův algoritmus - úvod


- **MCMC algoritmy** = třída algoritmů na vzorkování z π pomocí MŘ, jehož matici přechodu P neznáme (opačná úloha k hledání SR MŘ)
- *Proč?* Obrovské stavové prostory, kde $|\mathcal{X}| \rightarrow +\infty$ (nelze zde vzorkovat klasicky)

MCMC - Metropolisův algoritmus - úvod

- **MCMC algoritmy** = třída algoritmů na vzorkování z π pomocí MŘ, jehož matici přechodu P neznáme (opačná úloha k hledání SR MŘ)
- *Proč?* Obrovské stavové prostory, kde $|\mathcal{X}| \rightarrow +\infty$ (nelze zde vzorkovat klasicky)
- + Nezávisí na normovací konstantě rozdělení (stačí znát jen váhu konfigurace)

MCMC - Metropolisův algoritmus - úvod

- **MCMC algoritmy** = třída algoritmů na vzorkování z π pomocí MŘ, jehož matici přechodu P neznáme (opačná úloha k hledání SR MŘ)
- *Proč?* Obrovské stavové prostory, kde $|\mathcal{X}| \rightarrow +\infty$ (nelze zde vzorkovat klasicky)
- + Nezávisí na normovací konstantě rozdělení (stačí znát jen váhu konfigurace)
- - Kdy algoritmus zastavit?



MCMC - Metropolisův algoritmus - symetrická verze

- Mějme nějaký Markovský řetězec se **symetrickou** maticí přechodu Ψ , mn. stavů \mathcal{X} a lib. SR
- *Jak tento řetězec modifikovat, aby měl stacionární rozdělení π ?*

MCMC - Metropolisův algoritmus - symetrická verze

- Mějme nějaký Markovský řetězec se **symetrickou** maticí přechodu Ψ , mn. stavů \mathcal{X} a lib. SR
 - *Jak tento řetězec modifikovat, aby měl stacionární rozdělení π ?*
 - Ve stavu x je další krok generován z rozdělení $\Psi(x, \cdot)$
 - Ozn. návrh na další stav y
 - Přijmeme y jako další stav s pravděpodobností $a(x, y)$
 - Zamítneme y jako další stav s pravděpodobností $1 - a(x, y)$
- Zamítání stavů snižuje účinnost algoritmu, ale je důležité pro zisk π*

MCMC - Metropolisův algoritmus - symetrická verze

- Mějme nějaký Markovský řetězec se **symetrickou** maticí přechodu Ψ , mn. stavů \mathcal{X} a lib. SR
 - *Jak tento řetězec modifikovat, aby měl stacionární rozdělení π ?*
 - Ve stavu x je další krok generován z rozdělení $\Psi(x, \cdot)$
 - Ozn. návrh na další stav y
 - Přijmeme y jako další stav s pravděpodobností $a(x, y)$
 - Zamítneme y jako další stav s pravděpodobností $1 - a(x, y)$
- Zamítání stavů snižuje účinnost algoritmu, ale je důležité pro získání π*
- Matice přechodu hledané modifikace původního MŘ

$$P(x, y) = \begin{cases} \Psi(x, y) a(x, y) & \dots & y \neq x \\ 1 - \sum_{z \neq x} \Psi(x, z) a(x, z) & \dots & y = x \end{cases}$$

MCMC - Metropolisův algoritmus - symetrická verze

- Mějme nějaký Markovský řetězec se **symetrickou** maticí přechodu Ψ , mn. stavů \mathcal{X} a lib. SR
 - *Jak tento řetězec modifikovat, aby měl stacionární rozdělení π ?*
 - Ve stavu x je další krok generován z rozdělení $\Psi(x, \cdot)$
 - Ozn. návrh na další stav y
 - Přijmeme y jako další stav s pravděpodobností $a(x, y)$
 - Zamítneme y jako další stav s pravděpodobností $1 - a(x, y)$
- Zamítání stavů snižuje účinnost algoritmu, ale je důležité pro zisk π*
- Matice přechodu hledané modifikace původního MŘ

$$P(x, y) = \begin{cases} \Psi(x, y) a(x, y) & \dots & y \neq x \\ 1 - \sum_{z \neq x} \Psi(x, z) a(x, z) & \dots & y = x \end{cases}$$

Jak ale volit pravděpodobnost $a(x, y)$?

MCMC - Metropolisův algoritmus - symetrická verze

- Z balanční rovnováhy víme, že P má SR π , pokud

$$\pi(x) \Psi(x, y) a(x, y) = \pi(y) \Psi(y, x) a(y, x), \quad \forall y \neq x$$

MCMC - Metropolisův algoritmus - symetrická verze

- Z bilanční rovnováhy víme, že P má SR π , pokud

$$\pi(x) \Psi(x, y) a(x, y) = \pi(y) \Psi(y, x) a(y, x), \quad \forall y \neq x$$

- Ze symetrie Ψ pak máme

$$\pi(x) a(x, y) = \pi(y) a(y, x)$$

MCMC - Metropolisův algoritmus - symetrická verze

- Z balanční rovnáhy víme, že P má SR π , pokud

$$\pi(x) \Psi(x, y) a(x, y) = \pi(y) \Psi(y, x) a(y, x), \quad \forall y \neq x$$

- Ze symetrie Ψ pak máme

$$\pi(x) a(x, y) = \pi(y) a(y, x)$$

- Ozn. $b(x, y) := \pi(x) a(x, y)$, potom z $a(y, x) \leq 1$ získáme $b(y, x) \leq \pi(y)$, odkud

$$b(x, y) \leq \pi(y),$$

$$\text{takže } a(x, y) \leq \frac{\pi(y)}{\pi(x)}$$

MCMC - Metropolisův algoritmus - symetrická verze

- Z balanční rovnováhy víme, že P má SR π , pokud

$$\pi(x) \Psi(x, y) a(x, y) = \pi(y) \Psi(y, x) a(y, x), \quad \forall y \neq x$$

- Ze symetrie Ψ pak máme

$$\pi(x) a(x, y) = \pi(y) a(y, x)$$

- Ozn. $b(x, y) := \pi(x) a(x, y)$, potom z $a(y, x) \leq 1$ získáme $b(y, x) \leq \pi(y)$, odkud

$$b(x, y) \leq \pi(y),$$

$$\text{takže } a(x, y) \leq \frac{\pi(y)}{\pi(x)}$$

- Vybereme co největší, abychom co nejméně zamítali

$$a(x, y) = \min \left\{ \frac{\pi(y)}{\pi(x)}, 1 \right\}$$

- Úplně obdobně jako v symetrické verzi

$$a(x, y) = \min \left\{ \frac{\pi(y) \Psi(y, x)}{\pi(x) \Psi(x, y)}, 1 \right\}$$

MCMC - Metropolisův algoritmus - náš případ

- Budeme zde používat symetrickou verzi
- Chceme olomit na náš případ Boltzmannova rozdělení, tj.

$$\pi(x) \propto \exp \{-\beta U(x)\}, \quad \beta \in \mathbb{R}^+$$

- Odvodili jsme, že $a(x, y) = \min \left\{ \frac{\pi(y)}{\pi(x)}, 1 \right\}$
- Pro Boltzmann: $\tilde{a}(x, y) := \frac{\pi(y)}{\pi(x)} = e^{-\beta(U(y)-U(x))}$

MCMC - Metropolisův algoritmus - náš případ

- Budeme zde používat symetrickou verzi
- Chceme olomit na náš případ Boltzmannova rozdělení, tj.

$$\pi(x) \propto \exp \{-\beta U(x)\}, \quad \beta \in \mathbb{R}^+$$

- Odvodili jsme, že $a(x, y) = \min \left\{ \frac{\pi(y)}{\pi(x)}, 1 \right\}$
- Pro Boltzmann: $\tilde{a}(x, y) := \frac{\pi(y)}{\pi(x)} = e^{-\beta(U(y)-U(x))}$
 - Pokud $\tilde{a}(x, y) < 1$, pak $a(x, y) = \tilde{a}(x, y)$, což odpovídá podmínce:
Pokud $U(y) > U(x)$, pak kandidáta y přijmu jako nový stav s pravděpodobností $\tilde{a}(x, y)$

MCMC - Metropolisův algoritmus - náš případ

- Budeme zde používat symetrickou verzi
- Chceme olomit na náš případ Boltzmannova rozdělení, tj.

$$\pi(x) \propto \exp \{-\beta U(x)\}, \quad \beta \in \mathbb{R}^+$$

- Odvodili jsme, že $a(x, y) = \min \left\{ \frac{\pi(y)}{\pi(x)}, 1 \right\}$
- Pro Boltzmannu: $\tilde{a}(x, y) := \frac{\pi(y)}{\pi(x)} = e^{-\beta(U(y)-U(x))}$
 - Pokud $\tilde{a}(x, y) < 1$, pak $a(x, y) = \tilde{a}(x, y)$, což odpovídá podmínce:

Pokud $U(y) > U(x)$, pak kandidáta y přijmu jako nový stav s pravděpodobností $\tilde{a}(x, y)$

- Pokud $\tilde{a}(x, y) \geq 1$, pak $a(x, y) = 1$, což odpovídá podmínce:

Pokud $U(y) \leq U(x)$, pak kandidáta y přijmu jako nový stav vždy.

Algorithm 0.1: METROPOLIS()

$x \in \mathcal{X}$

$U = U(x)$

while nejsme spokojeni

do $\left\{ \begin{array}{l} y \sim \Psi(x, \cdot) \\ \text{if } U(y) \leq U(x) \\ \quad \text{then } \begin{cases} x \leftarrow y \\ U \leftarrow U(y) \end{cases} \\ \text{else } \begin{cases} \text{if } \text{rand} < e^{-\beta(U(y)-U(x))} \\ \quad \text{then } \begin{cases} x \leftarrow y \\ U \leftarrow U(y) \end{cases} \end{cases} \end{array} \right.$

- Volba $U(x)$:

$$U(x) = U(x_1, \dots, x_N) = \sum_{j=1}^N U_j(x_1, \dots, x_N),$$

kde $U_j(x_1, \dots, x_N) = g(x_j - x_{j-1})$, kde g je např. $g(d) = \frac{1}{d}$

- Volba symetrické $\Psi(x, y)$
 - Hýbáme všemi částicemi najednou:

$$y_j = x_j + \delta_j, \quad \forall j \in \hat{N}$$

kde $\delta_j \sim \mathcal{U}(-R, R)$, $R = \frac{L}{N} \cdot 0.1$ je šum a L je délka kruhu

- Předpokládáme pro jednoduchost, že $L = N$
- Předjíždění je zakázáno, tj. musí platit

$$y_j < y_{j-1}, \quad \forall j \in \hat{N}$$

Konec dnešní přednášky. :-)